

▼ Практическое задание №1

Установка необходимых пакетов:

```
!pip install -q tqdm
!pip install --upgrade --no-cache-dir gdown

Requirement already satisfied: gdown in /usr/local/lib/python3.12/dist-packages (5.2.0)
Requirement already satisfied: beautifulsoup4 in /usr/local/lib/python3.12/dist-packages (from gdown) (4.13.5)
Requirement already satisfied: filelock in /usr/local/lib/python3.12/dist-packages (from gdown) (3.20.0)
Requirement already satisfied: requests[socks] in /usr/local/lib/python3.12/dist-packages (from gdown) (2.32.4)
Requirement already satisfied: tqdm in /usr/local/lib/python3.12/dist-packages (from gdown) (4.67.1)
Requirement already satisfied: soupsieve>1.2 in /usr/local/lib/python3.12/dist-packages (from beautifulsoup4->gdown) (2
Requirement already satisfied: typing-extensions>=4.0.0 in /usr/local/lib/python3.12/dist-packages (from beautifulsoup4
Requirement already satisfied: charset_normalizer<4,>=2.5 in /usr/local/lib/python3.12/dist-packages (from requests[socks]
Requirement already satisfied: idna<4,>=2.5 in /usr/local/lib/python3.12/dist-packages (from requests[socks]->gdown) (3
Requirement already satisfied: urllib3<3,>=1.21.1 in /usr/local/lib/python3.12/dist-packages (from requests[socks]->gdo
Requirement already satisfied: certifi>=2017.4.17 in /usr/local/lib/python3.12/dist-packages (from requests[socks]->gdo
Requirement already satisfied: PySocks!=1.5.7,>=1.5.6 in /usr/local/lib/python3.12/dist-packages (from requests[socks]-
```

Монтирование Вашего Google Drive к текущему окружению:

```
from google.colab import drive
drive.mount('/content/drive', force_remount=True)

Mounted at /content/drive
```

Константы, которые пригодятся в коде далее, и ссылки (gdrive идентификаторы) на предоставляемые наборы данных:

```
EVALUATE_ONLY = False
TEST_ON_LARGE_DATASET = True
TISSUE_CLASSES = ('ADI', 'BACK', 'DEB', 'LYM', 'MUC', 'MUS', 'NORM', 'STR', 'TUM')
DATASETS_LINKS = {
    'train': '1XtQzVQ5XbrfxpLHJu0XBGJ5U7CS-cLi',
    'train_small': '1qd45XfDwdZjktLFwQb-et-mAaFeCzOR',
    'train_tiny': '1I-2Z0uXLd4QwhZQQltp817Kn3J0Xgbui',
    'test': '1RfPou3pFKpuHDJZ-D9XFzgvwpUBF1Dr',
    'test_small': '1wbRsog0n7uGlHIPGLhyN-PMeT2kdQ2lI',
    'test_tiny': '1viiB0s041CnsAK4itvX8PnYthJ-MDnQc'
}
```

Импорт необходимых зависимостей:

```
from pathlib import Path
import numpy as np
from typing import List
from tqdm.notebook import tqdm
from time import sleep
from PIL import Image
import IPython.display
from sklearn.metrics import balanced_accuracy_score
import gdown
```

▼ Класс Dataset

Предназначен для работы с наборами данных, обеспечивает чтение изображений и соответствующих меток, а также формирование пакетов (батчей).

```
class Dataset:

    def __init__(self, name):
        self.name = name
        self.is_loaded = False
        url = f"https://drive.google.com/uc?export=download&confirm=pbef&id={DATASETS_LINKS[name]}"
        output = f'{name}.npz'
        gdown.download(url, output, quiet=False)
        print(f'Loading dataset {self.name} from npz.')
        np_obj = np.load(f'{name}.npz')
        self.images = np_obj['data']
        self.labels = np_obj['labels']
```

```

self.n_files = self.images.shape[0]
self.is_loaded = True
print(f'Done. Dataset {name} consists of {self.n_files} images.')

def image(self, i):
    # read i-th image in dataset and return it as numpy array
    if self.is_loaded:
        return self.images[i, :, :, :]

def images_seq(self, n=None):
    # sequential access to images inside dataset (is needed for testing)
    for i in range(self.n_files if not n else n):
        yield self.image(i)

def random_image_with_label(self):
    # get random image with label from dataset
    i = np.random.randint(self.n_files)
    return self.image(i), self.labels[i]

def random_batch_with_labels(self, n):
    # create random batch of images with labels (is needed for training)
    indices = np.random.choice(self.n_files, n)
    imgs = []
    for i in indices:
        img = self.image(i)
        imgs.append(self.image(i))
    logits = np.array([self.labels[i] for i in indices])
    return np.stack(imgs), logits

def image_with_label(self, i: int):
    # return i-th image with label from dataset
    return self.image(i), self.labels[i]

```

▼ Пример использования класса Dataset

Загрузим обучающий набор данных, получим произвольное изображение с меткой. После чего визуализируем изображение, выведем метку. В будущем, этот кусок кода можно закомментировать или убрать.

```

d_train_tiny = Dataset('train_tiny')

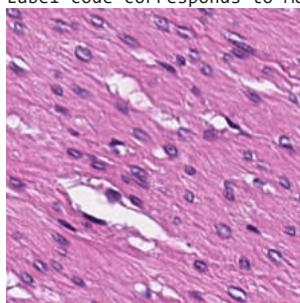
img, lbl = d_train_tiny.random_image_with_label()
print()
print(f'Got numpy array of shape {img.shape}, and label with code {lbl}.')
print(f'Label code corresponds to {TISSUE_CLASSES[lbl]} class.')

pil_img = Image.fromarray(img)
IPython.display.display(pil_img)

Downloading...
From: https://drive.google.com/uc?export=download&confirm=pbef&id=1I-2Z0uXLd40whZ001tp817Kn3J0Xgbui
To: /content/train_tiny.npz
100%|██████████| 105M/105M [00:02<00:00, 35.1MB/s]
Loading dataset train_tiny from npz.
Done. Dataset train_tiny consists of 900 images.

```

Got numpy array of shape (224, 224, 3), and label with code 5.
Label code corresponds to MUS class.



▼ Обёртка над Dataset для использования с PyTorch

```

# =====
# (Опционально) Обёртка над Dataset для использования с PyTorch
# =====

# ВНИМАНИЕ:
# Этот код нужен только тем, кто хочет решать задание с помощью PyTorch.

```

```
# Он показывает, как "подключить" наш Dataset к torch.utils.data.DataLoader.

try:
    import torch
    from torch.utils.data import Dataset as TorchDataset, DataLoader
    import torchvision.transforms as T
    from PIL import Image

    class HistologyTorchDataset(TorchDataset):
        """
        Обёртка над Dataset для использования с PyTorch.

        base_dataset: экземпляр Dataset('train'), Dataset('train_small'), etc.
        transform: функция/объект, преобразующий изображение (PIL.Image -> torch.Tensor).

        """
        def __init__(self, base_dataset, transform=None):
            self.base = base_dataset
            # Минимальный transform по умолчанию:
            # np.uint8 [0, 255] -> float32 [0.0, 1.0]
            self.transform = transform or T.ToTensor()

        def __len__(self):
            # Размер датасета
            return len(self.base.images)

        def __getitem__(self, idx):
            """
            Возвращает (image_tensor, label) для PyTorch.
            image_tensor: torch.Tensor формы [3, H, W]
            label: int
            """
            img, label = self.base.image_with_label(idx) # img: np.ndarray (H, W, 3)
            img = Image.fromarray(img) # в PIL.Image
            img = self.transform(img) # в torch.Tensor
            return img, label

    except ImportError:
        HistologyTorchDataset = None
        print("PyTorch / torchvision не найдены. Обёртка HistologyTorchDataset недоступна.")
```

▼ Пример использования класса HistologyTorchDataset

```
if "HistologyTorchDataset" not in globals() or HistologyTorchDataset is None:
    print("PyTorch не установлен или обёртка недоступна – пример пропущен.")
else:
    print("Пример использования PyTorch-обёртки над Dataset")

base_train = Dataset('train_tiny')

# Создаём PyTorch-совместимый датасет
train_ds = HistologyTorchDataset(base_train)

# DataLoader автоматически создаёт батчи и перемешивает данные
from torch.utils.data import DataLoader
train_loader = DataLoader(train_ds, batch_size=8, shuffle=True)

# Берём один батч и выводим информацию
images_batch, labels_batch = next(iter(train_loader))

print("Форма батча изображений:", tuple(images_batch.shape)) # [batch, 3, 224, 224]
print("Форма батча меток:", tuple(labels_batch.shape)) # [batch]
print("Пример меток:", labels_batch[:10].tolist())

print("Тип images_batch:", type(images_batch))
print("Тип labels_batch:", type(labels_batch))
```

Пример использования PyTorch-обёртки над Dataset
 Downloading...
 From: <https://drive.google.com/uc?export=download&confirm=pbef&id=1I-2Z0uXld40whZQ01tp817Kn3J0Xgbui>
 To: /content/train_tiny.npz
 100%[██████████] 105M/105M [00:02<00:00, 37.6MB/s]
 Loading dataset train_tiny from npz.
 Done. Dataset train_tiny consists of 900 images.
 Форма батча изображений: (8, 3, 224, 224)
 Форма батча меток: (8,)
 Пример меток: [3, 0, 8, 7, 5, 6, 2, 2]
 Тип images_batch: <class 'torch.Tensor'>
 Тип labels_batch: <class 'torch.Tensor'>

▼ Класс Metrics

Реализует метрики точности, используемые для оценивания модели:

1. точность,
2. сбалансированную точность.

```
class Metrics:

    @staticmethod
    def accuracy(gt: List[int], pred: List[int]):
        assert len(gt) == len(pred), 'gt and prediction should be of equal length'
        return sum(int(i[0] == i[1]) for i in zip(gt, pred)) / len(gt)

    @staticmethod
    def accuracy_balanced(gt: List[int], pred: List[int]):
        return balanced_accuracy_score(gt, pred)

    @staticmethod
    def print_all(gt: List[int], pred: List[int], info: str):
        print(f'metrics for {info}:')
        print('\t accuracy {:.4f}'.format(Metrics.accuracy(gt, pred)))
        print('\t balanced accuracy {:.4f}'.format(Metrics.accuracy_balanced(gt, pred)))
```

▼ Класс Model

Класс, хранящий в себе всю информацию о модели.

Вам необходимо реализовать методы save, load для сохранения и загрузки модели. Особенно актуально это будет во время тестирования на дополнительных наборах данных.

Пожалуйста, убедитесь, что сохранение и загрузка модели работает корректно. Для этого обучите модель, протестируйте ее в файл, перезапустите среду выполнения, загрузите обученную модель из файла, вновь протестируйте ее на тестовой выборке и убедитесь в том, что получаемые метрики совпадают с полученными для тестовой выборки ранее.

Также, Вы можете реализовать дополнительные функции, такие как:

1. валидацию модели на части обучающей выборки;
2. использование кроссвалидации;
3. автоматическое сохранение модели при обучении;
4. загрузку модели с какой-то конкретной итерации обучения (если используется итеративное обучение);
5. вывод различных показателей в процессе обучения (например, значение функции потерь на каждой эпохе);
6. построение графиков, визуализирующих процесс обучения (например, график зависимости функции потерь от номера эпохи обучения);
7. автоматическое тестирование на тестовом наборе/наборах данных после каждой эпохи обучения (при использовании итеративного обучения);
8. автоматический выбор гиперпараметров модели во время обучения;
9. сохранение и визуализацию результатов тестирования;
10. Использование аугментации и других способов синтетического расширения набора данных (дополнительным плюсом будет обоснование необходимости и обоснование выбора конкретных типов аугментации)
11. и т.д.

Полный список опций и дополнений приведен в презентации с описанием задания.

При реализации дополнительных функций допускается добавление параметров в существующие методы и добавление новых методов в класс модели.

```
#label1 – импорт
import gdown
import numpy as np
from sklearn.model_selection import train_test_split
from tqdm.auto import tqdm
import torch
import torch.nn as nn
import torch.optim as optim

#label2 – определение модели
class Model:
    def __init__(self, num_classes: int = 9):
        self.device = torch.device("cuda")
        self.num_classes = num_classes
```

```

self.num_classes = num_classes

#label3 - сверточный фиче-экстрактор
self.net = nn.Sequential(
    nn.Conv2d(3, 32, kernel_size=3, padding=1),
    nn.BatchNorm2d(32),
    nn.ReLU(inplace=True),
    nn.MaxPool2d(2),
    nn.Dropout(0.1),

    nn.Conv2d(32, 64, kernel_size=3, padding=1),
    nn.BatchNorm2d(64),
    nn.ReLU(inplace=True),
    nn.MaxPool2d(2),
    nn.Dropout(0.1),

    nn.Conv2d(64, 128, kernel_size=3, padding=1),
    nn.BatchNorm2d(128),
    nn.ReLU(inplace=True),
    nn.MaxPool2d(2),
    nn.Dropout(0.15),

    nn.AdaptiveAvgPool2d((1, 1)),
    nn.Flatten(),

    #label4 - классификатор
    nn.Linear(128, 256),
    nn.ReLU(inplace=True),
    nn.Dropout(0.4),
    nn.Linear(256, self.num_classes)
).to(self.device)

self.loss_fn = nn.CrossEntropyLoss(label_smoothing=0.1)
self.optimizer = optim.Adam(self.net.parameters(), lr=1e-3, weight_decay=1e-4)

self.scheduler = optim.lr_scheduler.ReduceLROnPlateau(
    self.optimizer,
    mode='min',
    factor=0.5,
    patience=2
)

#label5 - сохранение/загрузка
def save(self, name: str):
    path = f'/content/drive/MyDrive/{name}.pth'
    torch.save(self.net.state_dict(), path)

def load(self, name: str):
    path = f'/content/drive/MyDrive/{name}.pth'
    state = torch.load(path, map_location=self.device)
    self.net.load_state_dict(state)
    self.net.eval()

#label6 - препроцессинг изображения
def preprocess(self, img: np.ndarray, train=False) -> torch.Tensor:

    if img.ndim == 2:
        img = np.stack([img, img, img], axis=-1)

    if img.ndim == 3 and img.shape[0] == 3 and img.shape[2] != 3:
        img = np.transpose(img, (1, 2, 0))

    img = img.astype(np.float32)
    if img.max() > 1:
        img /= 255.0

    img = (img - 0.5) / 0.5

    img = np.transpose(img, (2, 0, 1))
    t = torch.tensor(img, dtype=torch.float32).unsqueeze(0)

    if train:
        if torch.rand(1).item() < 0.5:
            t = torch.flip(t, dims=[3])

        if torch.rand(1).item() < 0.5:
            t = nn.functional.pad(t, (4,4,4,4))
            t = nn.functional.interpolate(t, size=(224,224), mode='bilinear')

```

```

    return t.to(self.device)

#label7 – обучение
def train(self, dataset, epochs=25, batch_size=16):

    all_imgs = []
    all_labels = []

    for img, lbl in tqdm(zip(dataset.images_seq(dataset.n_files), dataset.labels),
                          total=dataset.n_files,
                          dynamic_ncols=True):
        all_imgs.append(img)
        all_labels.append(lbl)

    all_imgs = np.array(all_imgs, dtype=object)
    all_labels = np.array(all_labels)

    train_idx, val_idx = train_test_split(
        np.arange(dataset.n_files),
        test_size=0.1,
        shuffle=True,
        stratify=all_labels
    )

    print(f"Train: {len(train_idx)}, Val: {len(val_idx)}")

    self.net.train()
    best_val_loss = float('inf')

    for epoch in range(1, epochs+1):

        np.random.shuffle(train_idx)

        epoch_loss = 0
        correct = 0

        for start in tqdm(range(0, len(train_idx), batch_size),
                           desc=f"Epoch {epoch}",
                           dynamic_ncols=True):

            batch_ids = train_idx[start:start+batch_size]

            Xb = []
            yb = []

            for i in batch_ids:
                Xb.append(self.preprocess(all_imgs[i], train=True))
                yb.append(all_labels[i])

            Xb = torch.cat(Xb, dim=0)
            yb = torch.tensor(yb, dtype=torch.long, device=self.device)

            logits = self.net(Xb)
            loss = self.loss_fn(logits, yb)

            self.optimizer.zero_grad()
            loss.backward()
            self.optimizer.step()

            epoch_loss += loss.item() * len(batch_ids)
            preds = torch.argmax(logits, dim=1)
            correct += (preds == yb).sum().item()

        epoch_loss /= len(train_idx)
        acc = correct / len(train_idx)

        val_loss = 0
        val_correct = 0

        self.net.eval()
        with torch.no_grad():
            for i in val_idx:
                xb = self.preprocess(all_imgs[i], train=False)
                yb = torch.tensor([all_labels[i]], device=self.device)

                logits = self.net(xb)
                loss = self.loss_fn(logits, yb)

                val_loss += loss.item()
                pred = torch.argmax(logits, dim=1)
                val_correct += (pred == yb).sum().item()

```

```

    val_loss /= len(val_idx)
    val_acc = val_correct / len(val_idx)

    print(f"[Epoch {epoch}] train_loss={epoch_loss:.4f}, "
          f"val_loss={val_loss:.4f}, val_acc={val_acc*100:.2f}%)"

    self.scheduler.step(val_loss)

    if val_loss < best_val_loss:
        best_val_loss = val_loss
        self.save("best")
        print("Лучшая модель обновлена")

    self.net.train()

    print("Обучение завершено")
}

#label8 - тестирование
def test_on_image(self, img: np.ndarray) -> int:
    self.net.eval()
    with torch.no_grad():
        x = self.preprocess(img, train=False)
        logits = self.net(x)
        return torch.argmax(logits, dim=1).item()

def test_on_dataset(self, dataset, limit=None):
    self.net.eval()

    n = dataset.n_files if limit is None else int(dataset.n_files * limit)

    predictions = []
    correct = 0

    for i, img in tqdm(
        enumerate(dataset.images_seq(n)),
        total=n,
        dynamic_ncols=True,
        desc="Testing"
    ):
        pred = self.test_on_image(img)
        predictions.append(pred)

        if pred == dataset.labels[i]:
            correct += 1

    acc = correct / n
    print(f"Точность модели: {acc*100:.2f}%")

    return predictions

```

▼ Классификация изображений

Используя введенные выше классы можем перейти уже непосредственно к обучению модели классификации изображений. Пример общего пайплайна решения задачи приведен ниже. Вы можете его расширять и улучшать. В данном примере используются наборы данных 'train_small' и 'test_small'.

```

d_train = Dataset('train_small')
d_test = Dataset('test_small')

Downloading...
From: https://drive.google.com/uc?export=download&confirm=pbef&id=1qd45xFDwdZjktLFwQb-et-mAaFeCzOR
To: /content/train_small.npz
100%[██████████] 841M/841M [00:14<00:00, 57.1MB/s]
Loading dataset train_small from npz.
Done. Dataset train_small consists of 7200 images.
Downloading...
From: https://drive.google.com/uc?export=download&confirm=pbef&id=1wbRsog0n7uG1HIPGLhyN-PMeT2kd021I
To: /content/test_small.npz
100%[██████████] 211M/211M [00:05<00:00, 40.2MB/s]
Loading dataset test_small from npz.
Done. Dataset test_small consists of 1800 images.

```

```

model = Model()
if not EVALUATE_ONLY:

```

```
model.train(d_train)
model.save('best')
else:
    #todo: your link goes here
    model.load('best')
```

```

100%
Train: 6480, Val: 720
Epoch 1: 100%
[Epoch 1] train_loss=1.3667, val_loss=1.1040, val_acc=73.61%
Лучшая модель обновлена
Epoch 2: 100%
[Epoch 2] train_loss=1.1507, val_loss=1.0575, val_acc=75.69%
Лучшая модель обновлена
Epoch 3: 100%
[Epoch 3] train_loss=1.0797, val_loss=0.9528, val_acc=80.00%
Лучшая модель обновлена
Epoch 4: 100%
[Epoch 4] train_loss=1.0098, val_loss=0.9652, val_acc=79.72%
Epoch 5: 100%
[Epoch 5] train_loss=0.9777, val_loss=0.9344, val_acc=80.56%
Лучшая модель обновлена
Epoch 6: 100%
[Epoch 6] train_loss=0.9389, val_loss=0.8406, val_acc=86.94%
Лучшая модель обновлена
Epoch 7: 100%
[Epoch 7] train_loss=0.8946, val_loss=1.0058, val_acc=78.19%
Epoch 8: 100%
[Epoch 8] train_loss=0.8675, val_loss=0.8640, val_acc=85.28%
Epoch 9: 100%
[Epoch 9] train_loss=0.8617, val_loss=0.7770, val_acc=89.31%
Лучшая модель обновлена
Epoch 10: 100%
[Epoch 10] train_loss=0.8246, val_loss=0.7121, val_acc=93.33%
Лучшая модель обновлена
Epoch 11: 100%
[Epoch 11] train_loss=0.8107, val_loss=0.7137, val_acc=92.64%
Epoch 12: 100%
[Epoch 12] train_loss=0.8021, val_loss=0.8081, val_acc=89.17%
Epoch 13: 100%
[Epoch 13] train_loss=0.7818, val_loss=0.7930, val_acc=87.78%
Epoch 14: 100%
[Epoch 14] train_loss=0.7374, val_loss=0.6518, val_acc=94.86%
Лучшая модель обновлена
Epoch 15: 100%
[Epoch 15] train_loss=0.7312, val_loss=0.6524, val_acc=95.28%
Epoch 16: 100%
[Epoch 16] train_loss=0.7197, val_loss=0.6334, val_acc=96.53%
Лучшая модель обновлена
Epoch 17: 100%
[Epoch 17] train_loss=0.7226, val_loss=0.6429, val_acc=96.11%
Epoch 18: 100%
[Epoch 18] train_loss=0.7194, val_loss=0.6529, val_acc=95.28%
Epoch 19: 100%
[Epoch 19] train_loss=0.7110, val_loss=0.7040, val_acc=92.08%
Epoch 20: 100%
[Epoch 20] train_loss=0.6822, val_loss=0.6240, val_acc=96.39%
Лучшая модель обновлена
Epoch 21: 100%
[Epoch 21] train_loss=0.6810, val_loss=0.6276, val_acc=96.39%
Epoch 22: 100%
[Epoch 22] train_loss=0.6758, val_loss=0.6156, val_acc=96.81%
Лучшая модель обновлена
Epoch 23: 100%
[Epoch 23] train_loss=0.6790, val_loss=0.6161, val_acc=96.67%
Epoch 24: 100%
[Epoch 24] train_loss=0.6708, val_loss=0.6159, val_acc=95.83%
Epoch 25: 100%
[Epoch 25] train_loss=0.6651, val_loss=0.6047, val_acc=97.36%
Лучшая модель обновлена
Обучение завершено

```

7200/7200 [00:00<00:00, 266655.38it/s]

405/405 [01:29<00:00, 5.95it/s]

405/405 [01:35<00:00, 3.89it/s]

405/405 [01:09<00:00, 6.37it/s]

405/405 [01:09<00:00, 6.56it/s]

405/405 [01:09<00:00, 6.38it/s]

405/405 [01:10<00:00, 6.41it/s]

405/405 [01:10<00:00, 3.92it/s]

405/405 [01:09<00:00, 6.38it/s]

405/405 [01:09<00:00, 6.16it/s]

405/405 [01:09<00:00, 6.28it/s]

405/405 [01:09<00:00, 6.47it/s]

405/405 [01:10<00:00, 6.27it/s]

405/405 [01:10<00:00, 4.00it/s]

405/405 [01:09<00:00, 6.50it/s]

405/405 [01:09<00:00, 6.43it/s]

405/405 [01:09<00:00, 6.46it/s]

405/405 [01:09<00:00, 6.32it/s]

405/405 [01:10<00:00, 5.66it/s]

405/405 [01:10<00:00, 4.33it/s]

405/405 [01:09<00:00, 6.35it/s]

405/405 [01:09<00:00, 6.35it/s]

405/405 [01:08<00:00, 6.43it/s]

405/405 [01:10<00:00, 3.96it/s]

405/405 [01:09<00:00, 5.97it/s]

Пример тестирования модели на части набора данных:

```
# evaluating model on 10% of test dataset
pred_1 = model.test_on_dataset(d_test, limit=0.1)
Metrics.print_all(d_test.labels[:len(pred_1)], pred_1, '10% of test')
```

```
Testing: 100%
Точность модели: 100.00%
metrics for 10% of test:
accuracy 1.0000:
balanced accuracy 1.0000:
/usr/local/lib/python3.12/dist-packages/sklearn/metrics/_classification.py:407: UserWarning: A single label was found in
warnings.warn(
```

180/180 [00:00<00:00, 556.45it/s]

Пример тестирования модели на полном наборе данных:

```
# evaluating model on full test dataset (may take time)
if TEST_ON_LARGE_DATASET:
    pred_2 = model.test_on_dataset(d_test)
    Metrics.print_all(d_test.labels, pred_2, 'test')
```

```
Testing: 100%
Точность модели: 95.67%
metrics for test:
accuracy 0.9567:
balanced accuracy 0.9567:
```

1800/1800 [00:02<00:00, 661.52it/s]

Результат работы пайплайна обучения и тестирования выше тоже будет оцениваться. Поэтому не забудьте присылать на проверку ноутбук с выполненными ячейками кода с демонстрациями метрик обучения, графиками и т.п. В этом пайплайне Вам необходимо продемонстрировать работу всех реализованных дополнений, улучшений и т.п.

Настоятельно рекомендуется после получения пайплайна с полными результатами обучения экспортировать ноутбук в pdf (файл -> печать) и прислать этот pdf вместе с самим ноутбуком.

▼ Тестирование модели на других наборах данных

Ваша модель должна поддерживать тестирование на других наборах данных. Для удобства, Вам предоставляется набор данных `test_tiny`, который представляет собой малую часть (2% изображений) набора `test`. Ниже приведен фрагмент кода, который будет осуществлять тестирование для оценивания Вашей модели на дополнительных тестовых наборах данных.

Прежде чем отсылать задание на проверку, убедитесь в работоспособности фрагмента кода ниже.

```
final_model = Model()
final_model.load('best')
d_test_tiny = Dataset('test_tiny')
pred = final_model.test_on_dataset(d_test_tiny)
Metrics.print_all(d_test_tiny.labels, pred, 'test-tiny')

Downloading...
From: https://drive.google.com/uc?export=download&confirm=pbef&id=1viIB0s041CNsAK4itvX8PnYthJ-MDnQc
To: /content/test_tiny.npz
100%[██████████] 10.6M/10.6M [00:00<00:00, 53.7MB/s]
Loading dataset test_tiny from npz.
Done. Dataset test_tiny consists of 90 images.

Testing: 100%
Точность модели: 92.22%
metrics for test-tiny:
accuracy 0.9222:
balanced accuracy 0.9222:
```

90/90 [00:00<00:00, 440.80it/s]

Отмонтируйте Google Drive.

```
drive.flush_and_unmount()
```

▼ Дополнительные "полезности"

Ниже приведены примеры использования различных функций и библиотек, которые могут быть полезны при выполнении данного практического задания.

▼ Измерение времени работы кода

Измерять время работы какой-либо функции можно легко и непринужденно при помощи функции `timeit` из соответствующего модуля:

```
import timeit

def factorial(n):
    res = 1
    for i in range(1, n + 1):
        res *= i
    return res

def f():
    return factorial(n=1000)

n_runs = 128
print(f'Function f is calculated {n_runs} times in {timeit.timeit(f, number=n_runs)}s.')
Function f is calculated 128 times in 0.027159667999967496s.
```

▼ Scikit-learn

Для использования "классических" алгоритмов машинного обучения рекомендуется использовать библиотеку scikit-learn (<https://scikit-learn.org/stable/>). Пример классификации изображений цифр из набора данных MNIST при помощи классификатора SVM:

```
# Standard scientific Python imports
import matplotlib.pyplot as plt

# Import datasets, classifiers and performance metrics
from sklearn import datasets, svm, metrics
from sklearn.metrics import ConfusionMatrixDisplay
from sklearn.model_selection import train_test_split

# The digits dataset
digits = datasets.load_digits()

# The data that we are interested in is made of 8x8 images of digits, let's
# have a look at the first 4 images, stored in the `images` attribute of the
# dataset. If we were working from image files, we could load them using
# matplotlib.pyplot.imread. Note that each image must have the same size. For these
# images, we know which digit they represent: it is given in the 'target' of
# the dataset.
_, axes = plt.subplots(2, 4)
images_and_labels = list(zip(digits.images, digits.target))
for ax, (image, label) in zip(axes[0, :], images_and_labels[:4]):
    ax.set_axis_off()
    ax.imshow(image, cmap=plt.cm.gray_r, interpolation='nearest')
    ax.set_title('Training: %i' % label)

# To apply a classifier on this data, we need to flatten the image, to
# turn the data in a (samples, feature) matrix:
n_samples = len(digits.images)
data = digits.images.reshape((n_samples, -1))

# Create a classifier: a support vector classifier
classifier = svm.SVC(gamma=0.001)

# Split data into train and test subsets
X_train, X_test, y_train, y_test = train_test_split(
    data, digits.target, test_size=0.5, shuffle=False)

# We learn the digits on the first half of the digits
classifier.fit(X_train, y_train)

# Now predict the value of the digit on the second half:
predicted = classifier.predict(X_test)

images_and_predictions = list(zip(digits.images[n_samples // 2:], predicted))
for ax, (image, prediction) in zip(axes[1, :], images_and_predictions[:4]):
    ax.set_axis_off()
    ax.imshow(image, cmap=plt.cm.gray_r, interpolation='nearest')
    ax.set_title('Prediction: %i' % prediction)

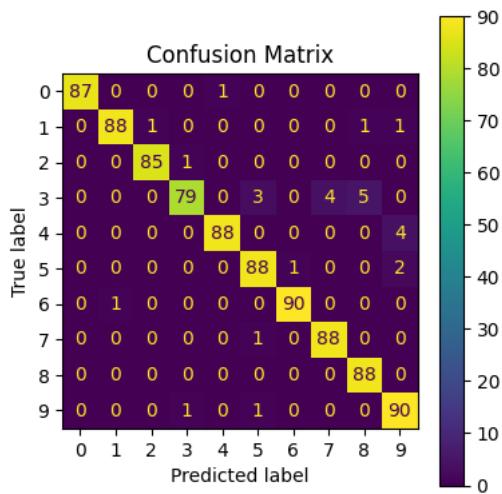
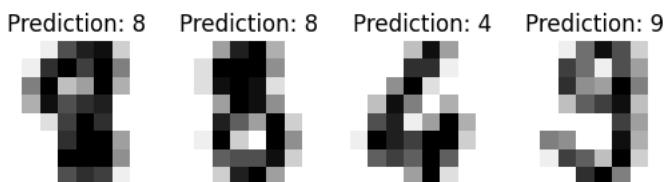
print("Classification report for classifier %s:\n%s\n"
      % (classifier, metrics.classification_report(y_test, predicted)))
```

```
# Матрица ошибок + визуализация в новом API
cm = metrics.confusion_matrix(y_test, predicted)
disp = ConfusionMatrixDisplay(confusion_matrix=cm,
                               display_labels=classifier.classes_)

fig, ax = plt.subplots(figsize=(4, 4))
disp.plot(ax=ax)
ax.set_title("Confusion Matrix")
plt.tight_layout()
plt.show()

Classification report for classifier SVC(gamma=0.001):
  precision    recall   f1-score   support
  0       1.00    0.99    0.99     88
  1       0.99    0.97    0.98     91
  2       0.99    0.99    0.99     86
  3       0.98    0.87    0.92     91
  4       0.99    0.96    0.97     92
  5       0.95    0.97    0.96     91
  6       0.99    0.99    0.99     91
  7       0.96    0.99    0.97     89
  8       0.94    1.00    0.97     88
  9       0.93    0.98    0.95     92

  accuracy                           0.97    899
  macro avg       0.97    0.97    0.97    899
  weighted avg    0.97    0.97    0.97    899
```



Scikit-image

Реализовывать различные операции для работы с изображениями можно как самостоятельно, работая с массивами numpy, так и используя специализированные библиотеки, например, scikit-image (<https://scikit-image.org/>). Ниже приведен пример использования Canny edge detector.

```
import numpy as np
import matplotlib.pyplot as plt
from scipy import ndimage as ndi
```

```

from skimage import feature

# Generate noisy image of a square
im = np.zeros((128, 128))
im[32:-32, 32:-32] = 1

im = ndi.rotate(im, 15, mode='constant')
im = ndi.gaussian_filter(im, 4)
im += 0.2 * np.random.random(im.shape)

# Compute the Canny filter for two values of sigma
edges1 = feature.canny(im)
edges2 = feature.canny(im, sigma=3)

# display results
fig, (ax1, ax2, ax3) = plt.subplots(nrows=1, ncols=3, figsize=(8, 3),
                                    sharex=True, sharey=True)

ax1.imshow(im, cmap=plt.cm.gray)
ax1.axis('off')
ax1.set_title('noisy image', fontsize=20)

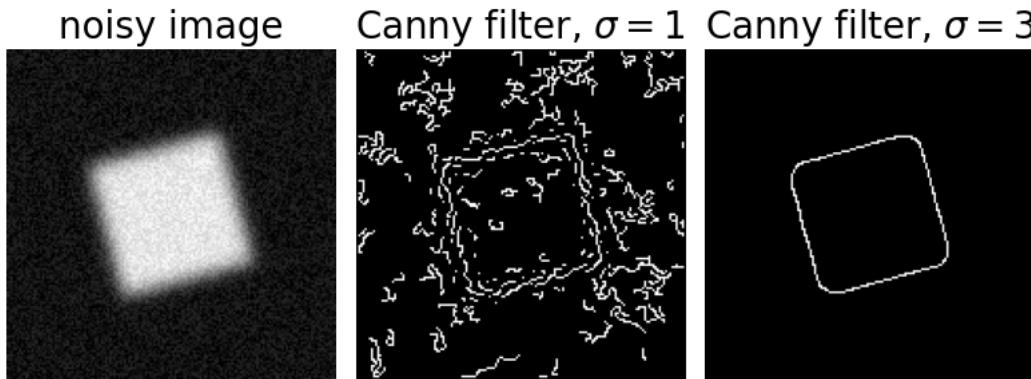
ax2.imshow(edges1, cmap=plt.cm.gray)
ax2.axis('off')
ax2.set_title(r'Canny filter, $\sigma=1$', fontsize=20)

ax3.imshow(edges2, cmap=plt.cm.gray)
ax3.axis('off')
ax3.set_title(r'Canny filter, $\sigma=3$', fontsize=20)

fig.tight_layout()

plt.show()

```



▼ Tensorflow 2

Для создания и обучения нейросетевых моделей можно использовать фреймворк глубокого обучения Tensorflow 2. Ниже приведен пример простейшей нейронной сети, использующейся для классификации изображений из набора данных MNIST.

```

# Install TensorFlow

import tensorflow as tf

mnist = tf.keras.datasets.mnist

(x_train, y_train), (x_test, y_test) = mnist.load_data()
x_train, x_test = x_train / 255.0, x_test / 255.0

model = tf.keras.models.Sequential([
    tf.keras.layers.Flatten(input_shape=(28, 28)),
    tf.keras.layers.Dense(128, activation='relu'),
    tf.keras.layers.Dropout(0.2),
    tf.keras.layers.Dense(10, activation='softmax')
])

model.compile(optimizer='adam',
              loss='sparse_categorical_crossentropy',
              metrics=['accuracy'])

model.fit(x_train, y_train, epochs=5)

model.evaluate(x_test, y_test, verbose=2)

```

```
Downloading data from https://storage.googleapis.com/tensorflow/tf-keras-datasets/mnist.npz
11490434/11490434          0s 0us/step
/usr/local/lib/python3.12/dist-packages/keras/src/layers/reshaping/flatten.py:37: UserWarning: Do not pass an `input_sh
super().__init__(**kwargs)
Epoch 1/5
1875/1875      6s 2ms/step - accuracy: 0.8569 - loss: 0.4820
Epoch 2/5
1875/1875      5s 3ms/step - accuracy: 0.9559 - loss: 0.1496
Epoch 3/5
1875/1875      4s 2ms/step - accuracy: 0.9683 - loss: 0.1034
Epoch 4/5
1875/1875      4s 2ms/step - accuracy: 0.9740 - loss: 0.0823
Epoch 5/5
1875/1875      5s 3ms/step - accuracy: 0.9776 - loss: 0.0746
313/313 - 2s - 5ms/step - accuracy: 0.9781 - loss: 0.0712
[0.07115683704614639, 0.9781000018119812]
```

Для эффективной работы с моделями глубокого обучения убедитесь в том, что в текущей среде Google Colab используется аппаратный ускоритель GPU или TPU. Для смены среды выберите "среда выполнения" -> "сменить среду выполнения".

Большое количество туториалов и примеров с кодом на Tensorflow 2 можно найти на официальном сайте <https://www.tensorflow.org/tutorials?hl=ru>.

Также, Вам может понадобиться написать собственный генератор данных для Tensorflow 2. Скорее всего он будет достаточно простым, и его легко можно будет реализовать, используя официальную документацию TensorFlow 2. Но, на всякий случай (если не удалось сразу разобраться или хочется вникнуть в тему более глубоко), можете посмотреть следующий отличный туториал: <https://stanford.edu/~shervine/blog/keras-how-to-generate-data-on-the-fly>.

▼ PyTorch

```
# =====
# Дополнительно: мини-демо PyTorch
# =====
# Ранний выход, если PyTorch/обёртка недоступны
try:
    import torch
    import torch.nn as nn
    import torch.nn.functional as F
    from torch.utils.data import DataLoader
except ImportError:
    print("PyTorch не установлен – демо пропущено.")
    import sys
    raise SystemExit

if "HistologyTorchDataset" not in globals() or HistologyTorchDataset is None:
    print("HistologyTorchDataset недоступна – демо пропущено.")
    import sys
    raise SystemExit

# --- Данные: tiny-наборы, чтобы выполнялось быстро ---
base_train = Dataset('train_tiny')
base_test = Dataset('test_tiny')

train_ds = HistologyTorchDataset(base_train)           # ToTensor по умолчанию
test_ds = HistologyTorchDataset(base_test)

train_loader = DataLoader(train_ds, batch_size=16, shuffle=True)
test_loader = DataLoader(test_ds, batch_size=32, shuffle=False)

# --- Мини-модель: двухслойный CNN + один FC (демонстрация, не решение) ---
class TinyCNN(nn.Module):
    def __init__(self, num_classes=len(TISSUE_CLASSES)):
        super().__init__()
        self.conv1 = nn.Conv2d(3, 8, kernel_size=3, padding=1)
        self.conv2 = nn.Conv2d(8, 16, kernel_size=3, padding=1)
        self.pool = nn.MaxPool2d(2, 2) # 224->112->56
        self.fc   = nn.Linear(16 * 56 * 56, num_classes)

    def forward(self, x):
        x = self.pool(F.relu(self.conv1(x))) # [B, 3, 224, 224] -> [B, 8, 112, 112]
        x = self.pool(F.relu(self.conv2(x))) # [B, 8, 112, 112] -> [B, 16, 56, 56]
        x = x.view(x.size(0), -1)
        x = self.fc(x)
        return x

device = torch.device("cuda" if torch.cuda.is_available() else "cpu")
```

```

print("Device:", device)

model = TinyCNN(num_classes=len(TISSUE_CLASSES)).to(device)
criterion = nn.CrossEntropyLoss()
optimizer = torch.optim.Adam(model.parameters(), lr=1e-3)

# --- Один учебный шаг "обучения" на одном батче ---
model.train()
xb, yb = next(iter(train_loader))
xb = xb.to(device)
yb = yb.to(device, dtype=torch.long)

optimizer.zero_grad()
logits = model(xb)
loss = criterion(logits, yb)
float_loss = float(loss.detach().cpu())
loss.backward()
optimizer.step()

print(f"Loss на одном батче train_tiny: {float_loss:.4f}")

# --- Быстрая проверка на одном батче теста (для формы вывода/метрик) ---
model.eval()
with torch.no_grad():
    xt, yt = next(iter(test_loader))
    xt = xt.to(device)
    logits_t = model(xt).cpu()
    y_pred = logits_t.argmax(dim=1).numpy()
    y_true = yt.numpy()

print("Размерности:", {"y_true": y_true.shape, "y_pred": y_pred.shape})
Metrics.print_all(y_true, y_pred, "_") # balanced accuracy/accuracy на одном батче для демонстрации

```

для полноценного решения требуется собственный тренировочный цикл по эпохам,

```

Downloading...
From: https://drive.google.com/uc?export=download&confirm=pbef&id=1I-2Z0uXLd40whZ001tp817Kn3J0Xgbui
To: /content/train_tiny.npz
100%|██████████| 105M/105M [00:00<00:00, 181MB/s]
Loading dataset train_tiny from npz.
Done. Dataset train_tiny consists of 900 images.
Downloading...
From: https://drive.google.com/uc?export=download&confirm=pbef&id=1viiB0s041CNsAK4itvX8PnYthJ-MDnQc
To: /content/test_tiny.npz
100%|██████████| 10.6M/10.6M [00:00<00:00, 186MB/s]
Loading dataset test_tiny from npz.
Done. Dataset test_tiny consists of 90 images.
Device: cuda
Loss на одном батче train_tiny: 2.1867
размерности: {'y_true': (32,), 'y_pred': (32,)}
metrics for _:
    accuracy 0.0000:
    balanced accuracy 0.0000:
/usr/local/lib/python3.12/dist-packages/sklearn/metrics/_classification.py:2524: UserWarning: y_pred contains classes n
warnings.warn("y_pred contains classes not in y_true")

```

Дополнительные ресурсы по PyTorch

- Официальные туториалы PyTorch — <https://pytorch.org/tutorials/>
- “Deep Learning with PyTorch: 60-Minute Blitz” — https://pytorch.org/tutorials/beginner/deep_learning_60min_blitz.html
- Transfer Learning for Computer Vision — https://pytorch.org/tutorials/beginner/transfer_learning_tutorial.html
- PyTorch Get Started (установка) — <https://pytorch.org/get-started/locally/>
- Dive into Deep Learning (D2L, глава PyTorch) — https://d2l.ai/chapter_preliminaries/index.html